



Penerapan Algoritma *Long Short Term Memory* (LSTM) Dalam Prediksi Pergerakan Harga *Cryptocurrency* Menggunakan Data *Time Series*

^{[1]*}Satrio Wahyutama, ^[2]Tedy Rismawan, ^[3]Syamsul Bahri

^{[1][2][3]}Jurusan Rekayasa Sistem Komputer, Fakultas Matematika dan Ilmu pengetahuan Alam, Universitas Tanjungpura, Pontianak, Indonesia

e-mail: ^{[1]*}swahyutama@student.untan.ac.id, ^[2]tedy_rismawan@siskom.untan.ac.id,
^[3]syamsul.bahri@siskom.untan.ac.id

Email Penulis Korespondensi: swahyutama@student.untan.ac.id

Submitted: 14/09/2025; Accepted: 25/09/2025; Published: 06/04/2026

Abstrak

Cryptocurrency merupakan teknologi *blockchain* yang diterapkan pada sistem desentralisasi, memiliki kebebasan, kecepatan dan keamanan dalam transaksi *cryptocurrency*, namun volatilitas yang tinggi merupakan bagian dari kelemahan yang dimiliki *cryptocurrency*. Kelemahan berupa volatilitas yang tinggi dimanfaatkan sebagai sarana investasi untuk mendapatkan keuntungan. Selain mendapatkan keuntungan, volatilitas yang tinggi dapat memberikan kerugian akibat kesalahan dalam menentukan pergerakan harga *cryptocurrency*. Hal ini membuat Prediksi diperlukan untuk dapat memprediksi pergerakan harga *cryptocurrency*. *Long Short Term Memory* (LSTM) merupakan salah satu algoritma yang dapat digunakan untuk memprediksi harga berdasarkan data *time series* harga *cryptocurrency* dimasa lalu. Oleh karena itu, pada penelitian ini dibangun sebuah sistem prediksi yang dapat memprediksi pergerakan harga *cryptocurrency*. Data yang digunakan yaitu data pergerakan harian BTC, ETH, dan ADA pada tanggal 1 Januari 2019-31 Maret 2024 (1917 data) dengan rasio data latih dan data uji adalah 70%:30%. Penelitian ini dilakukan untuk mengamati variasi arsitektur LSTM yang memiliki akurasi tertinggi. Hasil pengujian menunjukkan bahwa akurasi terbaik didapat dengan menggunakan variasi parameter 500 *max epoch*, 50 *neuron*, 128 *batch size* dan 0,001 *learning rate* pada BTC dengan hasil akurasi 98,42961%. Pada ETH menggunakan parameter 250 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate* mendapatkan akurasi sebesar 98,25673%. Sementara ADA menggunakan parameter 2000 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate* mendapatkan akurasi sebesar 97,50375%. Pengujian mendapatkan hasil terbaik pada setiap *cryptocurrency* dengan menggunakan dataset pada tanggal 1 Januari 2021 – 31 Maret 2024 (1186 data).

Kata kunci— *Cryptocurrency*, Prediksi, *Time series*, *Long Short Term Memory* (LSTM).

1. PENDAHULUAN

Perkembangan teknologi yang semakin pesat membuat aktivitas manusia sangat erat dengan peranan teknologi. Salah satu peranan perkembangan teknologi pada bidang keuangan yaitu adanya mata uang digital atau yang biasa disebut dengan *cryptocurrency*. *Cryptocurrency* memiliki keunggulan berupa teknologi *blockchain* yang diterapkan pada sistem desentralisasi. Teknologi tersebut tidak terikat dengan sistem perbankan *central*, selain itu mata uang digital ini memiliki kebebasan serta kecepatan dalam bertransaksi

serta keamanan identitas dalam melakukan transaksi *cryptocurrency* [1].

Cryptocurrency pada saat ini banyak diminati untuk menjadi media investasi dalam meraih keuntungan. Berdasarkan laporan Gemini berjudul “2022 *Global State of Crypto Report*” yang memuat survei kepada 30.000 responden *global* pada 20 negara periode November 2021-Februari 2022 didapat hasil bahwa, Indonesia menjadi salah satu negara selain Brazil sebagai negara dengan tingkat kepemilikan aset *Cryptocurrency* tertinggi dengan persentase mencapai 41 persen.





Indonesia menempati urutan teratas secara global untuk adopsi crypto secara keseluruhan [2]. Meski banyak peminat, investasi *cryptocurrency* sangat beresiko, tidak adanya aset yang mendasari harga *cryptocurrency* (*underlying asset*) menjadi permasalahan, membuat harga *cryptocurrency* memiliki volatilitas yang tinggi. Volatilitas yang tinggi ini menjadi kelemahan *cryptocurrency*, selain itu *cryptocurrency* dapat menjadi sarana dalam aksi kejahatan [3].

Cryptocurrency merupakan komoditas perdagangan yang memiliki volatilitas sangat tinggi dengan harga aset digital yang dapat mengalami kenaikan dan penurunan. Meski dapat memberikan keuntungan, investasi *cryptocurrency* memiliki resiko yang besar karena volatilitas pergerakan harga yang tidak menentu sehingga beresiko untuk dijadikan aset investasi, prediksi perlu dilakukan untuk mengetahui perkembangan dimasa yang akan datang berdasarkan *time series* atau informasi masa lalu. Prediksi tersebut diharapkan dapat memperkirakan kapan waktu yang tepat dalam melakukan transaksi *cryptocurrency*.

Long short term memory (LSTM) merupakan algoritma pengembangan dari *recurrent neural network* (RNN), dimana metode tersebut memiliki kelebihan yang jauh lebih baik dibandingkan dengan *recurrent neural network* yang dapat menyimpan informasi dalam jangka waktu yang panjang dengan menambahkan *memory cell*. Selain itu, LSTM dapat menjadi solusi saat memproses data sekuensial yang panjang sehingga mengatasi terjadinya *vanishing gradient*. Adanya *vanishing gradient* merupakan bagian dari kekurangan yang dimiliki oleh algoritma *Recurrent Neural Network* (RNN) dalam menangkap *long term dependencies*. Permasalahan tersebut dapat mengurangi akurasi dari suatu prediksi [4].

Penelitian mengenai metode LSTM pernah dilakukan oleh Cahyani dengan judul “Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional” [5]. Penelitian tersebut bertujuan untuk mengetahui harga bahan pokok nasional menggunakan 32 atribut dengan total data sebanyak 903 data. Pada model prediksi harga beras kualitas bawah II hasil yang diperoleh yaitu model terbaik dengan hasil evaluasi RMSE sebesar 0.0492

dan R2 score sebesar 0.8852, dengan menggunakan parameter learning rate sebesar 0.01, epoch sebanyak 50, batch size sebanyak 15, timestep sebanyak 10, dan LSTM layer sebanyak 3 *layer*. Pada model prediksi harga minyak goreng hasil yang diperoleh yaitu model terbaik dengan hasil evaluasi RMSE sebesar 0.0313 dan r2 score sebesar 0.7492, dengan menggunakan parameter learning rate sebesar 0.01, epoch sebanyak 200, batch size sebanyak 5, dan timestep sebanyak 10. Namun pada penelitian ini tidak menggunakan nilai parameter lain selain harga bahan pokok nasional, harga harian bahan pokok nasional digunakan untuk menghitung masing-masing atribut, prediksi pada atribut harga beras kualitas bawah II hanya menggunakan harga dari hari-hari sebelumnya.

Selanjutnya penelitian mengenai LSTM juga pernah dilakukan oleh Khumaidi dengan judul “Pengujian Algoritma *Long Short Term Memory* Untuk Prediksi Kualitas Udara Dan Suhu Kota Bandung” [6]. Penelitian tersebut bertujuan untuk melakukan prediksi kualitas udara dan suhu di kota Bandung. Data yang digunakan berupa data hasil pencatatan yang dimulai pada tanggal 19 Mei 2019 hingga 18 Agustus 2019 dengan menggunakan 21 parameter. Penelitian ini menggunakan 4 hidden layer, 32 batch size, 100 epoch dengan melakukan perhitungan terhadap data kualitas udara di Kota Bandung dengan parameter PM10, ISPU, serta suhu udara dan kelembaban. Hasil RMSE sebesar 3,15 untuk parameter suhu, 1,76 untuk parameter PM10, 6,97 untuk parameter kelembaban dan 1,85 untuk parameter ISPU. Namun pada penelitian ini tidak menggunakan variasi pada arsitektur *Long Short Term Memory*, hanya menggunakan satu arsitektur *Long Short Term Memory* yaitu dengan 4 hidden layer, 32 batch size, 100 epoch.


Selanjutnya penelitian lain terkait *cryptocurrency* dilakukan oleh Teja dengan judul “Penerapan Metode Extreme Learning Machine untuk Peramalan Harga Cryptocurrency” [2]. Dalam penelitian ini menggunakan data historis harian Bitcoin, Ethereum, dan Bnb yang berjumlah 1190 data dari tanggal 23 Agustus 2019 sampai 24 September 2022. Dilakukan percobaan dengan menggunakan 20 neuron hingga didapat hasil terbaik menggunakan MAPE dihasilkan pada

data Bitcoin dengan nilai kesalahan terkecil yaitu 2.8590%. Namun pada penelitian ini tidak menggunakan metode *Long Short Term Memory*, selain itu tidak menggunakan variasi arsitektur dari metode yang digunakan.

Berdasarkan latar belakang dan penelitian terkait yang telah diuraikan, maka dilakukan penelitian dengan judul “Penerapan Algoritma *Long Short Term Memory* (LSTM) Dalam Prediksi Pergerakan Harga *Cryptocurrency* Menggunakan Data Time Series”.

2. METODOLOGI PENELITIAN

Metode penelitian yang digunakan dalam prediksi pergerakan harga *cryptocurrency* dapat dilihat pada Gambar 1.



Gambar 1. Diagram Alir Penelitian


2.1 Studi Literatur

Pada studi literatur yaitu proses untuk mencari sumber-sumber yang berkaitan dan mendukung penelitian yang dilakukan. Literatur yang digunakan berupa jurnal yang berasal dari penelitian sebelumnya, buku-buku maupun artikel yang berkaitan dengan penelitian ini serta data yang dapat digunakan untuk mendukung penelitian ini, serta pengumpulan teori-teori atau referensi yang

berhubungan dengan algoritma *Long Short Term Memory*. Berikut adalah informasi yang diperoleh melalui pada studi literatur.

2.1.1 Recurrent Neural Network (RNN)


Recurrent Neural Network (RNN) adalah varian dari neural network yang cocok dalam pengolahan data berurutan (sekuensial). Cara yang dilakukan RNN untuk dapat menyimpan informasi dari masa lalu adalah dengan melakukan looping di dalam arsitekturnya, yang secara otomatis membuat informasi dari masa lalu tetap tersimpan [7]. Namun RNN mempunyai masalah *vanishing* dan *exploding gradient* yaitu apabila terjadi perubahan pada jangkauan nilai dari satu lapisan menuju lapisan berikutnya pada sebuah arsitektur [8]. Arsitektur RNN ditujukan pada Gambar 2.



Gambar 2. Arsitektur RNN

2.1.2 Long Short Term Memory (LSTM)

merupakan turunan dari metode RNN. LSTM menyimpan informasi terhadap pola-pola pada data dengan mempelajari data mana saja yang akan disimpan dan data mana saja yang akan dibuang, karena pada setiap neuron LSTM memiliki beberapa *gates* (gerbang) yang mengatur memori pada setiap neuron itu sendiri [9]. LSTM sangat cocok untuk mengklasifikasi, memproses, dan membuat prediksi berdasarkan data time series. LSTM secara umum terdiri dari *memory cell*, *input gate*, *output gate*, dan *forget gate*. Arsitektur LSTM ditunjukkan pada Gambar 3.



Gambar 3. Struktur LSTM

Forget gate dalam LSTM menentukan informasi yang mana informasi tersebut dapat diteruskan atau dihilangkan. Hal ini dapat terjadi karena adanya fungsi sigmoid yang menghasilkan angka

antara 0 dan 1. Angka 0 akan menunjukkan informasi dapat diberhentikan sedangkan angka 1 menunjukkan dapat diteruskan. Persamaan *forget gate* dituliskan pada Persamaan 1 [10].

$$f_t = \sigma(V_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

Keterangan:

f_t = *forget gate*

σ = fungsi sidmoid

W_f = nilai *weight* untuk *forget gate*

h_{t-1} = nilai *output* sebelum ke orde ke-t

x_t = nilai *input* sebelum ke orde ke-t

b_f = nilai bias pada *forget gate*

Input gate memiliki dua *gates* yang masing-masing memiliki fungsi, yaitu untuk memutuskan nilai mana yang akan diperbarui menggunakan fungsi aktivasi sigmoid, seperti pada Persamaan 2 [10].

$$i_t = \sigma(V_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

Keterangan:

i_t = *input gate*

σ = fungsi sidmoid

W_i = nilai *weight* untuk *input gate*

h_{t-1} = nilai *output* sebelum ke orde ke-t

x_t = nilai *input* sebelum ke orde ke-t

b_i = nilai bias pada *input gate*

Fungsi lain dari *input gate* adalah untuk membuat vector nilai baru yang akan disimpan pada *memory cell*. Vektor kandidat baru $\hat{c}$ dibuat melalui lapisan tanh untuk mengontrol berapa banyak informasi baru ditambahkan. Persamaan untuk mendapatkan nilai $\hat{C}_t$ dilihat pada Persamaan 3 [10].

$$\hat{C}_t = \tanh(V_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$

Keterangan:

$\hat{C}_t$ = Nilai baru yang ditambahkan ke *cell state*

$\tanh$ = Fungsi tanh

W_c = Nilai *weight* untuk *cell state*

h_{t-1} = Nilai *output* sebelum orde ke-t

x_t = Nilai *input* pada orde ke-t

b_c = Nilai bias pada *cell state*

Pada bagian *cell state* akan mengganti nilai pada *memory cell* sebelumnya (C_{t-1}) dengan nilai *memory cell* yang baru (C_t). Dimana nilai ini didapat dengan menggabungkan nilai yang terdapat pada *forget gate* dan *input gate*, untuk mendapatkan nilai *memory cell* yang baru menggunakan Persamaan 4 [10].

$$C_t = f_t \times C_{t-1} + i_t \times \hat{C}_t \quad (4)$$

Keterangan:

C_t = Nilai baru yang ditambahkan ke *cell state*

f_t = *Forget gate*

C_{t-1} = *Cell state* sebelum orde ke-t

i_t = *Input gate*

$\hat{C}_t$ = Nilai baru yang ditambahkan ke *cell state*

Output gates merupakan langkah terakhir dalam metode LSTM. Pada bagian *output gates*

terdapat dua *gates* yang dilakukan, lapisan sigmoid memutuskan bagian mana dari *cell state* yang akan dikeluarkan menjadi *output*, selanjutnya ditempatkan nilai pada *cell state* dengan menggunakan fungsi tanh untuk mendapatkan nilai dengan range -1 hingga 1. Kemudian kedua *gates* tersebut dikalikan sehingga menghasilkan nilai keluaran, seperti pada Persamaan 5 [10].

$$O_t = \sigma(V_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

Keterangan:

O_t = *Output gate*

σ = Fungsi sigmoid

W_o = Nilai *weight* untuk *output gate*

h_{t-1} = Nilai *output* sebelum orde ke-t

x_t = Nilai *input* pada orde ke-t

b_o = Nilai bias pada *output gate*

$$h_t = O_t \times \tanh(C_t) \quad (6)$$

Keterangan:

h_t = Nilai *output* orde ke t

O_t = *Output gate*

$\tanh$ = Fungsi tanh

C_t = *Cell state*

2.1.3 Optimasi Adam

Optimasi Adam bertujuan menghitung *adaptive learning rate* untuk setiap parameter. *Learning rate* menentukan seberapa banyak perubahan bobot pada jaringan. Berikut ini merupakan persamaan untuk optimasi Adam [11].

Menghitung gradien gt pada waktu t

$$gt = \nabla \theta_{t-1} (\theta_{t-1}) \quad (7)$$

Memperbarui bias momen vektor pertama

$$m_t = \beta_1 \times m_{t-1} + (1 - \beta_1) \times \nabla L(\theta_t) \quad (8)$$

Memperbarui bias momen vektor kedua

$$v_t = \beta_2 \times v_{t-1} + (1 - \beta_2) \times (\nabla L(\theta_t))^2 \quad (9)$$

Menghitung bias momen vektor pertama

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (10)$$

Menghitung momen vektor kedua

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (11)$$

Memperbarui parameter dengan menggunakan *learning rate*

$$\theta_{t+1} = \theta_t - \alpha \times \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (12)$$

Keterangan :

θ_t = parameter yang akan di *update*

α = *learning rate*

m_t = momen pertama

v_t = momen kedua

t = Iterasi saat ini

β_1 = parameter untuk mengontrol *momentum moving averages* pertama

$(\beta_1 = 0.9)$
 β_2 = parameter untuk mengontrol *momentum moving averages* kedua
 $(\beta_2 = 0.999)$
 $\hat{m}_t$ = koreksi momen pertama
 $\hat{v}_t$ = koreksi momen kedua
 ϵ = nilai untuk mencegah pembagian dengan 0 (1×10^{-8})

2.1.4 Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (MAPE) merupakan ukuran kesalahan relatif. MAPE menyatakan presentasi kesalahan hasil peramalan terhadap permintaan aktual selama periode tertentu yang akan memberikan informasi persentasi kesalahan. MAPE dirumuskan sebagai berikut. [12]

$$MAPE = \left(\frac{100}{N} \right) \sum |x_t - \frac{f_t}{x_t}| \quad (13)$$

Keterangan:

x_t = Nilai riil pada periode ke t
 f_t = Nilai peramalan pada periode ke t
 n = Jumlah periode peramalan

2.1.5 Fungsi Aktivasi

Fungsi aktivasi digunakan untuk menentukan keluaran (*output*) dari suatu neuron. Fungsi ini memiliki tujuan untuk memodifikasi *output* kedalam rentang nilai tertentu. Masukan-masukan akan dijumlahkan kemudian hasil dari penjumlahan tersebut akan masuk dalam fungsi aktivasi. Fungsi aktivasi yang digunakan dalam penelitian ini adalah fungsi *sigmoid biner* dan *tanh*.

2.1.5.1 Fungsi Sigmoid biner

Fungsi *sigmoid biner* memiliki interval nilai 0 sampai 1. Fungsi ini sering digunakan untuk jaringan yang membutuhkan nilai *output* yang terletak di interval 0 sampai 1. Fungsi *sigmoid biner* dirumuskan dengan Persamaan 14. [13]

$$f(x) = \frac{1}{1+e^{-x}} \quad (14)$$

Turunan dari fungsi *sigmoid biner* pada persamaan 14.

$$f'(x) = (y \times (1 - y)) \quad (15)$$

Keterangan :

y = Output
 $f(x)$ = fungsi aktivasi *sigmoid biner*
 e^{-x} = ekponensial pangkat minus data ke-x

2.1.5.1 Fungsi Tanh

Fungsi aktivasi ini hampir sama dengan fungsi aktivasi *sigmoid biner*, hanya saja *output* dari fungsi ini memiliki *range* antara 1 sampai -1. Fungsi aktivasi tanh dirumuskan dengan Persamaan 16. [13]

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (16)$$

Turunan dari fungsi aktivasi tanh dirumuskan dengan Persamaan 17.

$$f'(x) = (1 - y^2) \quad (17)$$

Keterangan :

y = Output
 $f(x)$ = fungsi aktivasi *tanh*
 e^{-x} = ekponensial pangkat minus data ke-x

2.1.6 Normalisasi

Normalisasi data merupakan suatu proses untuk mentransformasikan data ke dalam rentang tertentu. Skala rentang data yang sering digunakan biasanya berkisar antara 0-1. Metode normalisasi data ke dalam rentang 0-1 yang sering digunakan adalah metode *min-max normalization*, ditunjukkan pada Persamaan 18. [14].

$$v' = \frac{v - \min_A}{\max_A - \min_A} \quad (18)$$

Keterangan:

v' = Data normalisasi
 v = Data aktual
 $\min_A$ = Nilai terkecil dari data aktual
 $\max_A$ = Nilai terbesar dari data actual

2.1.7 Denormalisasi

Denormalisasi adalah proses pengembalian data hasil normalisasi ke dalam data asli atau data sebenarnya. Hal tersebut dilakukan guna melihat hasil prediksi dengan cara membandingkan dengan data sebenarnya. Denormalisasi dinyatakan dengan rumus Persamaan 19 [14].

$$v = v' (\max_A - \min_A) + \min_A \quad (19)$$

2.1.8 Cryptocurrency

Cryptocurrency berasal dari bahasa Inggris dan terdiri dari dua kata: kriptografi (yang mengacu pada cara untuk memastikan kerahasiaan komunikasi) dan mata uang (*currency*). *Cryptocurrency* adalah mata uang digital *decentralized* yang memverifikasi dan mengenkripsi transaksi keuangan yang dilakukan melalui jaringan menggunakan prinsip kriptografi dan ilmu keamanan komunikasi.

Cryptocurrency, sering dikenal sebagai uang digital adalah jenis aset digital yang dirancang untuk digunakan sebagai media perdagangan atau transaksi. Volatilitas yang tinggi merupakan bagian dari kelemahannya yang dimiliki *cryptocurrency*. *Cryptocurrency*

memiliki keunggulan berupa teknologi blockchain yang diterapkan pada sistem desentralisasi. Teknologi tersebut tidak terikat dengan sistem perbankan *central*, selain itu mata uang digital ini memiliki kebebasan serta kecepatan dalam bertransaksi serta keamanan identitas dalam melakukan transaksi *cryptocurrency* [1]

2.1.9 Prediksi

Prediksi adalah usaha menduga atau memperkirakan sesuatu yang akan terjadi di waktu mendatang dengan memanfaatkan berbagai informasi yang relevan pada waktu-waktu sebelumnya (*historis*) melalui suatu metode ilmiah. Tujuan dari prediksi adalah mendapatkan informasi apa yang akan terjadi di masa datang dengan probabilitas kejadian terbesar. Metode prediksi dapat dilakukan secara kualitatif melalui pendapat para pakar atau secara kuantitatif dengan perhitungan secara matematis [15].

2.2 Metode Pengumpulan Data

Pengumpulan data dilakukan dengan cara mengambil data *history* harga *cryptocurrency* melalui laman *coinmarketcap.com*. Data yang digunakan dalam penelitian ini yaitu data BTC, ETH dan ADA berupa harga pembukaan (*open price*), harga tertinggi (*high price*), harga terendah (*low price*), harga penutupan (*close price*), volume peredaran (*volume*) dan kapitalisasi pasar (*Market cap*) *cryptocurrency*. Data harga *cryptocurrency* masing-masing sebanyak 1917 data, dimulai dari 1 Januari 2019-31 Maret 2024.

2.3 Analisis Kebutuhan

Pada tahap analisis kebutuhan dilakukan untuk mendukung kinerja sistem prediksi harga *cryptocurrency* dengan menggunakan metode *Long Short Term Memory* (LSTM). Kebutuhan yang diperlukan pada penelitian ini berupa perangkat keras dan perangkat lunak yang diperlukan agar tercapai tujuan yang diinginkan.

2.4 Perancangan Sistem

Perancangan dilakukan dengan menggunakan metode *long short term memory* (LSTM) untuk prediksi pergerakan harga *cryptocurrency* yang akan dibuat berdasarkan


studi literatur yang telah dipelajari sebagai panduan dalam implementasi pembuatan sistem.

2.4.1 Perancangan Arsitektur Sistem

Arsitektur sistem LSTM yang digunakan pada penelitian ini memiliki struktur yang terdiri dari *input layer*, *hidden layer*, dan *output layer*. Arsitektur LSTM dapat dilihat pada Gambar 4. Konfigurasi LSTM yang digunakan dalam pelatihan dan pengujian pada Tabel 1

Tabel 1. Konfigurasi LSTM

Parameter	Nilai
<i>Input layer</i>	6
<i>hidden layer</i>	1-2
<i>output layer</i>	1
Pembagian data	70%:30%
<i>Epoch</i>	100;250;500
<i>Batch size</i>	16;32;64
<i>Neuron</i>	50;20;10
<i>Learning Rate</i>	0,1;0,01;0,001



Gambar 4. Arsitektur LSTM

Keterangan:

Lapisan Input layer terdiri dari 9 node yaitu:

x_1 = Harga Penutupan(C)

x_2 = Harga Tertinggi(H)

x_3 = Harga Terendah(L)

x_4 = Harga Pembukaan(O)


x_5 = Volume Perdagangan(V)

x_6 = Kapitalisasi Pasar(MC)

z = Lapisan *hidden layer*

Lapisan output layer terdiri dari 1 node yang menghasilkan nilai keluaran berupa hasil prediksi harga penutupan *cryptocurrency*.


Tahapan proses penerapan LSTM untuk prediksi harga *cryptocurrency* dapat dilihat pada Gambar 5




Gambar 5. Tahapan proses algoritma LSTM

Sistem dimulai dengan memasukkan dataset, dataset tersebut terbagi menjadi data latih dan data uji. Data yang digunakan sebagai input merupakan data pergerakan harian *cryptocurrency* yang meliputi *open, high, low, close, volume, market capital*. Selanjutnya dilakukan proses prediksi dengan menggunakan algoritma *Long Short Term Memory (LSTM)* dan menghasilkan output berupa prediksi harga *cryptocurrency*.

Pada algoritma LSTM memiliki dua proses yaitu proses pelatihan dan proses pengujian. proses pelatihan dan pengujian dirancang menggunakan *flowchart*. *Flowchart* LSTM dapat didefinisikan sebagai bagan yang dapat menunjukkan algoritma LSTM. Gambar tersebut menjelaskan urutan serta prosedur yang dilakukan oleh LSTM. *Flowchart* LSTM dapat dilihat pada Gambar 6 dan Gambar 7.



Gambar 6. Tahap Pelatihan LSTM



Gambar 7. Tahap pengujian LSTM

2.5 Implementasi

Implementasi perangkat lunak hasil dari perancangan sistem berupa aplikasi prediksi harga *cryptocurrency* yang dibuat meliputi Halaman login, Halaman dashboard, halaman pengujian, dan halaman pelatihan. Pada tampilan antarmuka halaman login merupakan halaman yang terdapat form untuk masuk kedalam sistem berupa *email* dan *password*. Tampilan antarmuka halaman *login* pada Gambar 8.




Gambar 8. Halaman Login

Halaman *dashboar* menampilkan informasi berupa data-data yang telah dilakukan dalam sistem, seperti jumlah pelatihan dan pengujian yang dilakukan, serta menampilkan grafik dari pengujian yang telah dilakukan. Tampilan antarmuka halaman dashboard pada Gambar 9.




Gambar 9. Halaman Dashboard

Halaman pelatihan menampilkan informasi berupa pelatihan yang telah dilakukan serta parameter-parameter yang digunakan dalam proses pelatihan yaitu *batch size*, *learning rate*, *epoch*, *neuron*, dan *hidden layer*. Tampilan antarmuka halaman pelatihan pada Gambar 10.



Gambar 10. Halaman Pelatihan

Pada halaman pengujian menampilkan informasi berupa pengujian yang telah dilakukan, terdapat informasi berupa file pengujian dan model yang digunakan serta nilai MAPE. Selain itu terdapat menu untuk melihat perbandingan hasil prediksi dengan data uji. Tampilan antarmuka halaman pengujian pada Gambar 11.



Gambar 11. Halaman Pengujian

2.6 Pengujian

Pengujian dilakukan untuk mendapatkan untuk mendapatkan akurasi terbaik dengan melakukan percobaan variasi parameter-parameter yang digunakan. Parameter-parameter yang digunakan yaitu *neuron*, *hidden layer*, *epoch*, *batch size*, *learning rate*. Pada setiap percobaan dilakukan pembagian data dengan komposisi rasio 70%:30% dimana rasio 70% akan digunakan sebagai data latih dan rasio 30% digunakan sebagai data uji.

3. HASIL DAN PEMBAHASAN

Penerapan metode LSTM pada penelitian ini dilakukan dengan menggunakan data harga harian *cryptocurrency* tanggal 1 Januari 2019

sampai dengan 31 Maret 2024. Data tersebut dibagi menjadi 3 dataset, yaitu *dataset 5* tahun, *dataset 3* tahun dan *dataset 1* tahun. Masing-masing dataset dibagi menjadi data latih 70% dan data uji 30%. Pelatihan yang dilakukan dengan menggunakan variasi parameter yaitu jumlah *neuron hidden layer*, jumlah *hidden layer*, nilai *max epoch*, *batch size* dan *learning rate*, hal ini dilakukan untuk mendapatkan arsitektur dengan akurasi terbaik dalam proses pengujian pada setiap *cryptocurrency*.

Pengujian dilakukan dengan melakukan percobaan menggunakan *dataset 5* tahun (1 Januari 2019 - 31 Maret 2024), 3 tahun (1 Januari 2021 - 31 Maret 2024) dan 1 tahun (1 Januari 2023 - 31 Maret 2024). Percobaan ini dilakukan dengan pembagian data pelatihan dan data pengujian. Pada dataset 5 tahun 70% data akan digunakan sebagai data latih (1342 data) dan 30% data akan digunakan sebagai data uji (575 data). Pada dataset 3 tahun 70% data akan digunakan sebagai data latih (830 data) dan 30% data akan digunakan sebagai data uji (356 data). Pada *dataset 1* tahun, 70% data akan digunakan sebagai data latih (320 data) dan 30% data akan digunakan sebagai data uji (136 data). Parameter yang digunakan yaitu *neuron hidden layer 50*, *learning rate 0.001*, *max epoch 500*, *batch size 64*.

Tabel 2. Akurasi Parameter Pengujian Dataset

NO.	Dataset (Tahun)	Neuron	Learning Rate	Epoch	Batch	Akurasi (%)		
						BTC	ETH	ADA
1	1	50	0,001	500	64	97,98576	97,28637	96,72662
2	3	50	0,001	500	64	98,38334	98,17938	97,36669
3	5	50	0,001	500	64	97,73339	97,86680	97,24761

Dari hasil percobaan terhadap variasi *dataset* pada Tabel 2, pengujian dilakukan dengan komposisi data latih 70% dan data uji 30%, hasil nilai akurasi terbaik yaitu pengujian dengan menggunakan *dataset 3* tahun pada setiap *cryptocurrency* yang digunakan. Pada BTC didapat akurasi 98,38334%, ETH mendapat akurasi 98,17938%, dan ADA mendapat akurasi 97,36669%. Dari keseluruhan pengujian yang dilakukan didapatkan akurasi terbaik *cryptocurrency* pada penggunaan *dataset* BTC. Pada pengujian terhadap variasi *dataset* ini tidak dapat mempresentasikan bahwa penggunaan *dataset* dalam rentang waktu yang lebih lama dapat memberikan akurasi yang semakin baik, maupun sebaliknya.

Pada pengujian *neuron hidden layer*, Parameter pengujian *neuron hidden layer* yang digunakan adalah 100, 50, 25, 10 dan 5 neuron pada *hidden layer*, parameter lain yang digunakan yaitu *batch size* 64, *max epoch* 500, *learning rate* 0,001.

Tabel 3. Akurasi Parameter Pengujian *Neuron Hidden Layer*

No	neuron	learning rate	epoch	batch	Akurasi (%)		
					BTC	ETH	ADA
1	100	64	500	0,001	98,30804	98,22718	97,37543
2	50	64	500	0,001	98,38334	98,17938	97,36669
3	25	64	500	0,001	98,40419	98,03493	97,36305
4	10	64	500	0,001	98,24118	98,06860	97,13036
5	5	64	500	0,001	98,24427	98,13574	96,77960

Pada parameter pengujian variasi *neuron hidden layer*, didapat hasil pada Tabel 3 menunjukkan bahwa jumlah *neuron hidden layer* yang banyak tidak dapat meresrepresentasikan bahwa hasil yang didapat akan semakin baik, begitu juga sebaliknya, jumlah *neuron hidden layer* yang sedikit tidak dapat meresrepresentasikan bahwa hasil yang didapat akan buruk karena tidak ada aturan pasti dalam penentuan jumlah *neuron hidden layer* yang cocok dalam suatu prediksi data *time series*. Akurasi terbaik yang didapat pada BTC dengan menggunakan *neuron hidden layer* 20 neuron sebesar 98,40419%. Pada ETH dan ADA didapat akurasi terbaik dengan menggunakan 100 *neuron hidden layer*, yaitu 98,22718% pada ETH, dan 97,37543% pada ADA.

Pada pengujian *max epoch*, parameter pengujian yang digunakan adalah 50, 100, 250, 500 dan 1000 *max epoch*, parameter lain yang digunakan yaitu *neuron hidden layer* 50 neuron, *batch size* 64, *learning rate* 0,001.

Tabel 4. Akurasi Parameter Pengujian *Epoch*

No	Epoch	Neuron	Batch size	learning rate	Akurasi (%)		
					BTC	ETH	ADA
1	4000	50	64	0,001	98,33064	98,23103	97,45131
2	2000	50	64	0,001	98,37491	98,19091	97,50375
3	1000	50	64	0,001	98,36712	98,15668	97,40708
4	500	50	64	0,001	98,38334	98,17938	97,36669
5	250	50	64	0,001	98,39780	98,25673	97,29462

Pada parameter pengujian *max epoch*, didapat hasil pada Tabel 4, berdasarkan pengujian yang dilakukan dengan

menggunakan variasi 5 *max epoch*, didapat hasil akurasi terbaik yaitu pengujian dengan menggunakan BTC dengan parameter 250 *max epoch* didapat hasil akurasi 98,39780%. Pada pengujian menggunakan ETH didapat akurasi terbaik yaitu 98,25673% dengan menggunakan 250 *max epoch*, pada pengujian menggunakan ADA didapat hasil terbaik yaitu 97,50375% dengan percobaan menggunakan 2000 *max epoch*. Pada pengujian terhadap variasi *max epoch* ini tidak dapat mempresentasikan bahwa penggunaan *max epoch* yang semakin banyak dapat memberikan akurasi yang semakin baik, maupun sebaliknya, berdasarkan pengujian yang dilakukan terhadap *cryptocurrency* yang digunakan, dilakukan percobaan (*trial error*) untuk mendapatkan hasil yang baik.

Pada pengujian *batch size*, parameter pengujian yang digunakan adalah 8, 16, 32, 64 dan 128 *batch size*, parameter lain yang digunakan yaitu *neuron hidden layer* 50 neuron, *max epoch* 500, *learning rate* 0,001.

Tabel 5. Akurasi Parameter Pengujian *Batch Size*

No	Batch Size	Neuron	Epoch	Learning Rate	Akurasi (%)		
					BTC	ETH	ADA
1	128	50	500	0,001	98,42961	98,23422	97,37628
2	64	50	500	0,001	98,38334	98,17938	97,36669
3	32	50	500	0,001	98,13707	98,13328	97,34540
4	16	50	500	0,001	98,27179	97,95938	97,19903
5	8	50	500	0,001	98,16495	97,58243	96,90322

Pada Pengujian parameter *batch size* dilakukan dengan menggunakan 5 variasi *batch size*, hasil pengujian terdapat pada Tabel 5. *batch size* merupakan jumlah sampel dari dataset yang akan digunakan pada proses pelatihan untuk setiap iterasi. Tidak ada aturan baku terkait jumlah *batch size* yang harus digunakan, jumlah *batch size* yang digunakan sangat terkait dengan jumlah *dataset* yang digunakan dalam proses pelatihan. Dengan menggunakan 5 variasi *batch size* menunjukkan akurasi terbaik pada setiap *cryptocurrency* yaitu pengujian dengan menggunakan 128 *batch size* dengan akurasi 98,42961% untuk BTC, akurasi 98,23422% untuk percobaan ETH, dan akurasi 97,37628% untuk percobaan ADA. Berdasarkan percobaan dengan 5 variasi *batch size* terhadap dataset ADA dan ETH, dapat meresrepresentasikan semakin besar variasi *batch*



size yang digunakan akan mendapatkan hasil yang semakin baik.

Pada pengujian *learning rate*, parameter nilai pengujian *learning rate* yang digunakan yaitu 0,001-0,01 *learning rate*, parameter lain yang digunakan yaitu *neuron hidden layer* 50 *neuron*, *max epoch* 500, *batch size* 64.

Tabel 6. Akurasi Parameter Pengujian *Learning Rate*

No	Learning Rate	Epoch	Neuron	Batch	Akurasi (%)		
					BTC	ETH	ADA
1	0,001	500	50	64	98,38334	98,17938	97,36669
2	0,002	500	50	64	98,32185	98,22534	97,32818
3	0,003	500	50	64	98,31448	97,06515	95,55713
4	0,004	500	50	64	98,11639	97,34070	95,62789
5	0,005	500	50	64	98,14635	95,96695	96,83850
6	0,006	500	50	64	98,15276	95,75358	96,60198
7	0,007	500	50	64	98,28572	96,91274	94,64392
8	0,008	500	50	64	96,99964	96,32270	95,87346
9	0,009	500	50	64	98,05749	96,24927	95,78079
10	0,01	500	50	64	98,25336	97,59517	95,66714

Parameter pengujian *learning rate* dapat dilihat pada Tabel 6. Tidak ada aturan pasti yang menyebutkan *learning rate* yang cocok digunakan dalam suatu prediksi. *Learning rate* yang terlalu kecil akan mengakibatkan laju perubahan pada bobot dalam mencari solusi menjadi pelan sedangkan jika *learning rate* terlalu besar maka akan mengakibatkan laju perubahan bobot dalam langkah mencari solusi menjadi sangat besar hingga sulit menemukan solusi. Berdasarkan pengujian yang dilakukan menunjukan bahwa jumlah *learning rate* yang semakin kecil dapat meresrepresentasikan bahwa hasil yang didapat akan semakin baik, semakin besar nilai *learning rate* membuat akurasi yang didapat akan cenderung semakin kecil. Hasil percobaan dengan variasi *learning rate* dengan nilai 0,001 sampai dengan 0,01, akurasi terbaik pada setiap *cryptocurrency* yaitu pada pengujian dengan menggunakan *learning rate* 0.001 untuk BTC dan ADA, dengan akurasi 98,38334% untuk BTC dan 97,36669% untuk ADA. Sementara itu akurasi terbaik pada pengujian ETH didapat dengan menggunakan *learning rate* 0,002 dengan akurasi 98,22534%.

Parameter dengan 2 *hidden layer* yang digunakan yaitu dengan kombinasi *neuron* yang berjumlah 100, 50, 25, 10 dan 5 *neuron*. Parameter lain yang digunakan yaitu *learning rate* 0.001, *max epoch* 500, *batch size* 64.

Tabel 7. Akurasi Parameter Pengujian Dengan 2 *Hidden Layer*

No	Neuron		Learning Rate	Epoch	Batch	Akurasi (%)		
	Hidden 1	Hidden 2				BTC	ETH	ADA
1	100	50	0,001	500	100	98,08873	97,47710	96,29069
2	100	25	0,001	500	100	98,34565	97,43242	96,31797
3	100	10	0,001	500	100	98,33224	97,48957	95,98514
4	100	5	0,001	500	100	98,32895	98,17854	97,07413
5	50	25	0,001	500	50	98,31883	97,67748	97,08942
6	50	10	0,001	500	50	98,38803	97,79278	96,65710
7	50	5	0,001	500	50	98,40450	97,36760	96,88350
8	25	10	0,001	500	25	98,35951	97,85257	97,27934
9	25	5	0,001	500	25	98,26378	97,34856	96,87023
10	10	5	0,001	500	10	98,17249	97,06739	96,82373

Parameter pengujian dengan 2 *hidden layer* dengan variasi nilai *neuron* pada tiap-tiap *hidden layer* dapat dilihat pada Tabel 7 Hasil pengujian dengan 2 *hidden layer*, akurasi terbaik pada BTC didapat pada pengujian dengan variasi 50 dan 5 *neuron* yaitu 98,40450%, pada ETH akurasi terbaik didapat pada percobaan dengan menggunakan variasi 100 dan 5 *neuron* yaitu 98,17854%, pada ADA akurasi terbaik didapat pada percobaan dengan menggunakan variasi 25 dan 10 *neuron* yaitu 97,27934%. Berdasarkan percobaan yang dilakukan dengan pengujian 2 *hidden layer* tidak dapat meresrepresentasikan bahwa hasil yang didapat akan lebih baik dibandingkan jika hanya menggunakan 1 *hidden layer*.

Berdasarkan keseluruhan pengujian yang dilakukan dengan melakukan percobaan (*trial error*) terhadap berbagai parameter yang digunakan, didapat hasil Akurasi terbaik pada setiap *cryptocurrency*. Pada BTC pengujian dengan menggunakan *dataset* 3 tahun yang memiliki parameter 500 *max epoch*, 50 *neuron*, 128 *batch size* dan 0,001 *learning rate*. Pengujian ini mendapatkan akurasi 98,42961%. Pada ETH pengujian dengan menggunakan *dataset* 3 tahun yang memiliki parameter 250 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate*. Pengujian ini mendapatkan akurasi 98,25673%. Pada ADA pengujian dengan menggunakan *dataset* 3 tahun yang memiliki parameter 2000 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate*. Pengujian ini mendapatkan akurasi 97,50375.

Prediksi *cryptocurrency* dengan sistem yang dibangun menggunakan algoritma LSTM dapat menjadi bantuan dan memberikan gambaran tentang pergerakan harga



cryptocurrency. Berdasarkan keseluruhan pengujian terhadap percobaan-percobaan parameter yang digunakan didapat akurasi yang sangat baik yaitu lebih dari 94%, akurasi ini diharapkan dapat memberikan gambaran tentang harga penutupan cryptocurrency yang akan datang. *Cryptocurrency* merupakan salah satu investasi yang memiliki tingkat pengembalian yang tinggi, hal ini sebanding dengan resiko yang dimiliki oleh *cryptocurrency*, investasi *cryptocurrency* perlu dilakukan dengan bijak agar dapat mengurangi kerugian dan mendapatkan keuntungan yang besar.

4. KESIMPULAN

Penerapan algoritma *Long Short Term Memory* (LSTM) dalam prediksi pergerakan harga *cryptocurrency* mendapatkan hasil akurasi tertinggi berdasarkan pengujian yang dilakukan sebesar 98,42961% pada BTC, 98,25673% pada ETH, dan 97,50375% pada ADA. Sedangkan nilai akurasi terendah berdasarkan percobaan yang dilakukan sebesar 97,73339% pada BTC, 95,75358% pada ETH, dan 94,64392% pada ADA. Hasil percobaan terhadap parameter-parameter yang digunakan menunjukan bahwa hasil akurasi terbaik didapat dengan menggunakan parameter 500 *max epoch*, 50 *neuron*, 128 *batch size* dan 0,001 *learning rate* pada BTC. Pada ETH menggunakan parameter 250 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate*. Sementara pada ADA menggunakan parameter 2000 *max epoch*, 50 *neuron*, 64 *batch size* dan 0,001 *learning rate*. Hasil percobaan ini mendapatkan akurasi terbaik dengan menggunakan dataset selama 3 tahun (1 Januari 2021 – 31 Maret 2024) yang terdiri dari 70% data latih dan 30% data uji.

DAFTAR PUSTAKA

- [1] Faizal, R., Setiawan, B. D., & Cholissodin, I. (2019). Prediksi Nilai Cryptocurrency Bitcoin menggunakan Algoritme Extreme Learning Machine (ELM). *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, Vol. 3(5), hal. 4226-4233.
- [2] Tejaya, L., Arisandi, D., & Hendryli, J. (2023). Penerapan Metode Extreme Learning Machine untuk Peramalan Harga Cryptocurrency. Program Studi Teknik Informatika, Universitas Tarumanagara, Jakarta, Indonesia.
- [3] Ausop, A. Z., dan Aulia, E. S. N., 2018., Teknologi Cryptocurrency Bitcoin Untuk Investasi Dan Transaksi Bisnis Menurut Syariat Islam. *Jurnal Sositoknologi*, 17(1), 74–92.
- [4] Girsang., A.,S., 2019., Long Short Term Memory (LSTM)., (Online, diakses Oktober 2023) <https://mti.binus.ac.id/2019/12/02/long-short-term-memory-lstm/>
- [5] Cahyani, J., Mujahidin, S., & Fiqar, T. P. (2023). Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional. *Jurnal Sistem Dan Teknologi Informasi (JustIN)*, 11(2), 346. <https://doi.org/10.26418/justin.v11i2.57395>
- [6] Khumaidi., A., Raafiudin., R., dan Solihin., P., I., 2020., Pengujian Algoritma Long Short Term Memory untuk Prediksi Kualitas Udara dan Suhu Kota Bandung., *Jurnal Telematika*, Vol.15 No. 1 ., Institut Teknologi Harapan Bangsa., Bandung.
- [7] Gema., A.,P., 2017., Recurrent Neural Network (RNN) dan Gated Recurrent Unit (GRU).,
- [8] Wiranda, L., & Sadikin, M. (2020). Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma. *Jurnal Nasional Pendidikan Teknik Informatika : JANAPATI*, 8(3), 184–196.
- [9] Yotenka, R., & El Huda, F. F. (2020). Implementasi Long Short-Term Memory Pada Harga Saham Perusahaan Perkebunan Di Indonesia. *Unisda Journal of Mathematics and Computer Science (UJMC)*, 6(01), 9–18.
- [10] Wardani., W., W., 2021., Prediksi Harga Saham Syariah Menggunakan Metode Recurrent Neural Network-Long Short Term Memory., Program Studi Matematika., Fakultas Sains Dan Teknologi., Universitas Islam Negeri Sunan Ampel Surabaya.
- [11] A. Wibowo, P. W. Wiryawan, and N. I. Nuqoyati, “Optimization of neural





network for cancer microRNA biomarkers classification,” in Journal of Physics: Conference Series, Institute of Physics Publishing, Jun. 2019. doi: 10.1088/1742-6596/1217/1/012124

- [12] Nasution, A. H., dan Prasetyawan, Y. (2008). *Perencanaan & Pengendalian Produksi*. Edisi Pertama. Graha Ilmu, Yogyakarta
- [13] Kusumadewi, S. (2003). *Artificial Intelligence (Teknik dan Aplikasinya)*. Yogyakarta: Graha Ilmu.
- [14] Wadi, H. (2020). Jaringan Syaraf Tiruan Backpropagation Menggunakan Python GUI : Langkah demi langkah memahami dan mengimplementasikan jaringan syaraf tiruan Backpropagation untuk prediksi data penjualan air minum dalam kemasan
- [15] Wanto, A., & Windarto, A. P. (2017). Analisis Prediksi Indeks Harga Konsumen Berdasarkan Kelompok Kesehatan Dengan Menggunakan Metode Backpropagation. *Jurnal & Penelitian Teknik Informatika*, 2(2), 37–44.